

Санкт-Петербургский государственный университет

Кафедра системного программирования

Группа 25.Б71-мм

Консольный архиватор файлов на основе алгоритма Хаффмана

КАЗАЧКОВ Роман Андреевич

Отчёт по учебной практике
в форме «Решение»

Научный руководитель:
старший преподаватель, к. т. н., Литвинов Ю. В.

Санкт-Петербург
2026

Оглавление

Введение	3
1. Постановка задачи	4
2. Обзор	5
2.1. Кодирование Хаффмана	5
2.2. Существующие решения	5
2.3. Выводы	6
3. Описание решения	7
3.1. Формат архива	7
3.2. Архитектура реализации	7
3.3. Инженерное оформление	8
4. Эксперимент	9
4.1. Условия и исследовательские вопросы	9
4.2. Проверка корректности	9
4.3. Метрики и результаты измерений	10
4.4. Ограничения воспроизводимости	11
Заключение	12
Список литературы	13

Введение

Сжатие без потерь требуется в задачах, где восстановленный результат должен в точности совпадать с исходными данными: при хранении текстов, программ, документов и произвольных бинарных файлов. Одним из базовых методов энтропийного кодирования является алгоритм Хаффмана, предложенный Д. А. Хаффманом в 1952 г. [4]. Он сопоставляет частым символам короткие двоичные слова, а редким — более длинные, сохраняя возможность однозначного декодирования.

Промышленные форматы архивов, такие как `gzip` и `ZIP`, применяют кодирование Хаффмана не изолированно, а в составе алгоритма `DEFLATE` вместе с поиском повторяющихся последовательностей [1, 3]. Поэтому на их примере непосредственное влияние дерева Хаффмана на размер и время обработки данных наблюдать неудобно. Для изучения алгоритма полезен самостоятельный инструмент с простым документированным форматом файла, воспроизводимой сборкой и автоматическими проверками.

Целью работы является разработка на языке `C` консольного архиватора, который сжимает и без потерь восстанавливает текстовые и бинарные файлы при помощи статического кодирования Хаффмана, а также проверка его корректности и исследование поведения на данных разных типов.

В работе предложен архивный формат, содержащий размер исходного файла и таблицу частот всех байтов; реализованы модули построения дерева, побитового ввода-вывода и кодирования; подготовлены тесты и скрипты измерений. Работа выполнена во втором семестре учебной практики. Исходный код открыт и доступен в репозитории проекта¹.

¹Репозиторий «Huffman Archiver», URL: <https://github.com/RomanKazz/huffman-archiver> (дата обращения: 27 мая 2026 г.).

1. Постановка задачи

Конечным пользователем решения является пользователь командной строки, которому необходим небольшой архиватор и воспроизводимая реализация алгоритма Хаффмана для учебных экспериментов. Пользователь должен иметь возможность сжать произвольный файл, восстановить его без потерь и повторить измерения на опубликованном коде.

Целью работы является реализация архиватора файлов на основе статического кодирования Хаффмана и экспериментальная проверка его свойств. Для достижения цели были поставлены следующие задачи:

1. выполнить обзор алгоритма Хаффмана и его применения в существующих средствах сжатия;
2. спроектировать формат архива и реализовать сжатие и распаковку текстовых и бинарных файлов;
3. обеспечить проверку корректности реализации модульными и интеграционными тестами, а также средствами автоматического анализа;
4. провести измерения коэффициента сжатия и времени обработки на данных с различными свойствами и проанализировать результаты.

Результатом работы должен быть опубликованный репозиторий консольной утилиты с инструкцией по сборке и запуску, описанием формата архива, автоматическими проверками и воспроизводимым сценарием измерений.

2. Обзор

2.1. Кодирование Хаффмана

Алгоритм Хаффмана строит оптимальный префиксный код для известного распределения частот символов [4]. Сначала для каждого символа создаётся лист дерева с весом, равным его частоте. Затем два узла с минимальными весами объединяются во внутренний узел; операция повторяется, пока не останется один корень. Путь от корня к листу задаёт двоичный код символа: переход влево соответствует биту 0, переход вправо — биту 1.

Префиксность означает, что ни один код символа не является началом другого кода. Поэтому декодирование выполняется последовательным обходом дерева по битам входного потока: достижение листа однозначно определяет восстановленный символ. В статическом варианте кодирования распределение частот определяется до начала записи сжатых данных; декодеру необходимо получить сведения, позволяющие восстановить то же дерево.

2.2. Существующие решения

В алгоритме DEFLATE кодирование Хаффмана применяется после этапа LZ77, который заменяет повторяющиеся фрагменты ссылками на уже обработанные данные [1]. Такой подход используется библиотекой `zlib` и утилитой `gzip` [3, 2]. Его преимуществом является более эффективное сжатие типичных файлов, поскольку учитываются не только частоты отдельных значений, но и повторяющиеся последовательности. Недостаток для целей данной работы состоит в том, что результат измерений характеризует комбинацию алгоритмов, а не отдельное кодирование Хаффмана.

Статический архиватор, реализованный в работе, занимает другую позицию: он хранит таблицу частот и применяет только побайтовое кодирование Хаффмана. Он уступает универсальным промышленным архиваторам как средство достижения максимального коэффициента

сжатия, но позволяет непосредственно изучать зависимость результата от распределения байтов и сохраняет простой формат архива.

2.3. Выводы

Для реализации выбран статический вариант алгоритма Хаффмана. Он соответствует цели работы, поскольку обеспечивает декодирование произвольных бинарных данных, допускает явное описание формата архива и позволяет измерить свойства именно энтропийного кодирования без влияния словарных методов.

3. Описание решения

3.1. Формат архива

Разработанный архив начинается с заголовка фиксированного размера 2060 байт, после которого располагается сжатый битовый поток. Заголовок позволяет проверить тип файла, восстановить дерево и прекратить декодирование после получения исходного количества байтов. Формат приведён в таблице 1.

Таблица 1: Формат создаваемого архива.

Поле	Размер	Назначение
<code>magic</code>	4 байта	сигнатура HUFF
<code>size</code>	8 байт	размер исходного файла, <code>uint64_t</code> , little-endian
<code>freq[256]</code>	2048 байт	таблица частот возможных байтов
<code>data</code>	переменный	битовый поток кодов Хаффмана

Таблица частот увеличивает размер малых архивов, но делает формат самодостаточным: распаковка не требует отдельного словаря или внешних метаданных. Представление размера файла и частот типом `uint64_t` исключает ограничение формата размером в 4 ГиБ.

3.2. Архитектура реализации

Реализация написана на языке C стандарта C11 и разделена на следующие модули:

- `main.c` разбирает аргументы командной строки и выбирает режим сжатия или распаковки;
- `huffman_codec.c` подсчитывает частоты, формирует заголовок, строит таблицу кодов и выполняет декодирование;
- `huffman_tree.c` строит и освобождает дерево Хаффмана, используя очередь с приоритетом на основе двоичной кучи;

- `bitio.c` реализует буферизованную запись и чтение отдельных битов в файловом потоке.

При сжатии файл читается сначала для подсчёта частот, затем повторно для записи кодовых слов в битовый поток. При распаковке читается заголовок, по таблице частот восстанавливается дерево и из потока выводится ровно число байтов, заданное полем `size`. Специально обработаны пустой вход и файл, состоящий из единственного различного символа: во втором случае символу назначается однокбитовый код.

3.3. Инженерное оформление

Сборка проекта описана средствами CMAKE; при стандартной конфигурации для исполняемого файла и тестов включается ADDRESSSANITIZER. В репозитории настроены процессы GITHUB Actions: сборка, модульные и интеграционные тесты, контроль форматирования `clang-format`, а также статический анализ CODEQL. В README приведены команды сборки и использования, описание формата архива и инструкция по запуску экспериментов. Исходный код распространяется под лицензией MIT.

4. Эксперимент

4.1. Условия и исследовательские вопросы

Проверка результата воспроизводилась 27 мая 2026 г. на компьютере с macOS (Darwin 25.4.0), AppleClang 21.0.0 и CMAKE 4.3.2. Проект компилировался с включённым ADDRESSSANITIZER. Для проверки были сформулированы следующие вопросы:

RQ1: восстанавливает ли утилита исходные данные без потерь для типовых и граничных входов?

RQ2: как распределение байтов во входном файле влияет на коэффициент сжатия статическим кодированием Хаффмана?

RQ3: какое время требуется на сжатие и распаковку файлов выбранного размера в подготовленном сценарии измерений?

4.2. Проверка корректности

Модульные тесты проверяют построение дерева, чтение и запись заголовка, побитовый ввод-вывод, основной кодек, случайные данные и обработку повреждённого входа. Интеграционный сценарий последовательно сжимает и распаковывает тестовые файлы, а затем сравнивает восстановленные данные с исходными. Итоги запуска приведены в таблице 2.

Таблица 2: Результаты проверки корректности реализации.

Проверка	Проверяемые свойства	Результат
Модульные тесты <code>ctest</code>	дерево, заголовок, битовый ввод-вывод, кодек, случайные данные, повреждённый вход	6/6
Интеграционный сценарий <code>tests/test.sh</code>	полный цикл сжатие–распаковка и побайтовое сравнение файлов	6/6

Интеграционные входы включают пустой файл, файл из повторяющегося символа, текст, набор всех значений байта и случайные бинарные данные. Таким образом, на вопрос RQ1 получен положительный ответ для предусмотренного набора проверок: все запущенные тесты прошли успешно.

4.3. Метрики и результаты измерений

Сценарий `experiments/run_all.sh` генерирует текстовые, повторяющиеся и случайные файлы размером 1, 10, 100 КиБ и 1 МиБ. Для каждого файла выполняется 10 запусков сжатия и распаковки. Основной метрикой размера является отношение размера архива к размеру исходного файла; значение меньше единицы означает уменьшение файла. Для времени приводятся среднее значение и выборочное среднеквадратичное отклонение.

Таблица 3: Обработка файлов размером 1 МиБ, 10 запусков; время указано в миллисекундах (меньше — лучше).

Тип данных	Отношение размеров	Сжатие, мс	Распаковка, мс
Повторяющийся символ	0,1270	$99,4 \pm 3,1$	$68,0 \pm 2,3$
Текст	0,5064	$118,3 \pm 2,6$	$87,1 \pm 2,8$
Случайные байты	1,0020	$129,2 \pm 4,1$	$97,6 \pm 2,5$

По вопросу RQ2 эксперимент показывает ожидаемую зависимость: файл с одним доминирующим символом уменьшается приблизительно до 12,7% исходного размера, текстовый файл — до 50,6%, а равномерно случайные байты практически не сжимаются. Для малых файлов накладные расходы заголовка становятся определяющими: архив случайного входа размером 1 КиБ имеет отношение размеров 2,9922. По вопросу RQ3 для файлов размером 1 МиБ время сжатия в измеренном наборе составляет от $99,4 \pm 3,1$ до $129,2 \pm 4,1$ мс, время распаковки — от $68,0 \pm 2,3$ до $97,6 \pm 2,5$ мс.

4.4. Ограничения воспроизводимости

Сценарии эксперимента позволяют повторить измерения, но результаты не являются бит-в-бит детерминированными. Файлы из набора `random` создаются из `/dev/urandom`, поэтому при каждом запуске имеют другое содержимое. Набор `binary` строится повторением системного исполняемого файла `/bin/ls` или значения переменной окружения `BINARY_SOURCE`; следовательно, его содержимое зависит от операционной системы и выбранного исходного файла, хотя размер каждого входа фиксируется скриптом.

Временные измерения зависят от процессора, нагрузки системы, версии компилятора и режима сборки. Поэтому приведённые значения следует рассматривать как характеристику конкретного окружения запуска, а не как переносимую оценку производительности на любой платформе. Для повторения полного сценария также требуются утилиты `python3`, `bc` и пакеты Python `pandas`, `matplotlib`, перечисленные в `README`.

Заключение

В рамках второго семестра учебной практики получены следующие результаты:

- выполнен обзор статического кодирования Хаффмана и его применения в составе существующих алгоритмов сжатия;
- разработан консольный архиватор на языке C с документированным бинарным форматом и поддержкой текстовых и бинарных файлов;
- корректность реализации проверена модульными и интеграционными тестами: в воспроизведённом запуске успешно прошли 6 из 6 модульных наборов тестов и обработаны 6 из 6 интеграционных входных файлов;
- проведены измерения на данных трёх типов; подтверждено эффективное сжатие избыточных данных и отсутствие выигрыша для равномерно случайного входа.

Исходный код, документация по сборке, описание формата и сценарии экспериментов опубликованы в репозитории проекта: <https://github.com/RomanKazz/huffman-archiver>. Версия, использованная в отчёте, соответствует опубликованному тегу v1.0.1: <https://github.com/RomanKazz/huffman-archiver/tree/v1.0.1>.

Для проекта настроены автоматические проверки сборки, тестов, форматирования и статического анализа при изменениях в репозитории. Дальнейшим развитием работы может быть устранение выявленных ограничений экспериментального сценария и сравнение результата с форматами, использующими DEFLATE.

Список литературы

- [1] DEFLATE Compressed Data Format Specification version 1.3 : Rep. : RFC 1951 / Internet Engineering Task Force ; Executor: L. Peter Deutsch : 1996. — URL: <https://www.rfc-editor.org/rfc/rfc1951>.
- [2] Free Software Foundation. GNU Gzip. — URL: <https://www.gnu.org/software/gzip/> (дата обращения: 27 мая 2026 г.).
- [3] Gailly Jean-loup, Adler Mark. zlib: A Massively Spiffy Yet Delicately Unobtrusive Compression Library. — URL: <https://zlib.net/> (дата обращения: 27 мая 2026 г.).
- [4] Huffman David A. A Method for the Construction of Minimum-Redundancy Codes // [Proceedings of the IRE](#). — 1952. — Vol. 40, no. 9. — P. 1098–1101. — URL: <https://ieeexplore.ieee.org/document/4051119>.